

Raonament Basat en Casos. Problemes en el Desenvolupament de Sistemes CBR

Miquel Sànchez-Marrè

CS - FIB- UPC

© Miquel Sànchez i Marrè, KEMLG, IDEAI-UPC, 2023

INDEX

PROBLEMES EN SISTEMES CBR JERÀRQUICS

- **Competència**
 - Valoració de la similitud
 - Informació desconeguda (valors que falten)
 - Discretització
 - Cerca infructuosa / Pèrdua de casos en estructures jeràrquiques
- **Eficiència en Temps**
 - Degradació de les estructures jeràrquiques
 - Overhead d'aprenentatge
- **Eficiència en Espai**
 - Quan és necessari aprendre un cas nou?
 - Hem d'oblidar alguns casos?

© Miquel Sànchez i Marrè, KEMLG, IDEAI-UPC, 2023

2

Competència

Valoració de la similitud

Competència - Valoració de la similitud

Valoració de la similitud

- Algoritmes Nearest Neighbour (NN)

$$\text{Full-dist}(C_i, C_j) = \sum_{k=1}^n w_k * \text{atr-dist}(C_{ik}, C_{jk}) / \sum_{k=1}^n w_k$$

- **Problemes:**

- **Es perd la rellevància dels atributs** quan n augmenta
- **La majoria només utilitzen valors quantitatius**

Distància l'Eixample: heterogènia i sensible al pes

[Sánchez-Marrè, 1996; Sánchez-Marrè et al., 1998]

$$d(C_i, C_j) = \frac{\sum_{k=1}^n e^{w_k} \times d(A_{ki}, A_{kj})}{\sum_{k=1}^n e^{w_k}}$$

$$d(A_i, A_j) = \begin{cases} \frac{|quantval(A_i) - quantval(A_j)|}{upperval(A_k) - lowerval(A_k)} & \text{if } A_k \text{ is an ordered attribute and } w_k \leq \alpha \\ \frac{|qualval(A_i) - qualval(A_j)|}{\#mod(A_k) - 1} & \text{if } A_k \text{ is an ordered attribute and } w_k > \alpha \\ 1 - \delta_{qualval(A_i), qualval(A_j)} & \text{if } A_k \text{ is a non - ordered attribute} \end{cases}$$

Proves experimentals (1)

$$\bullet d(C_i, C_j) = \left(\sum_{k=1}^n \text{weight}^r * |d(A_{ki}, A_{kj})|^r / \sum_{k=1}^n \text{weight}^r \right)^{1/r}$$

Similarity Measure	r	Weight	Ordered attributes d(A _{ki} , A _{kj})	
			W _k > α	W _k ≤ α
Discrete Manhattan (MD)	1	W _k	qlv(A _{ki}) - qlv(A _{kj}) / (#mod(A _k) - 1)	[a]
Discrete Euclidean (ED)	2	W _k	[a]	[a]
Discrete Exp.-weighted Manhattan (EMD)	1	e ^{w_k}	[a]	[a]
Continuous Manhattan (MC)	1	W _k	qtv(A _{ki}) - qtv(A _{kj}) / (upv(A _k) - lowv(A _k))	[b]
Continuous Euclidean (EC)	2	W _k	[b]	[b]
Continuous Exp.-weighted Manhattan (EMC)	1	e ^{w_k}	[b]	[b]
Weight-sensitive Manhattan (MW)	1	W _k	[a]	[b]
Weight-sensitive Euclidean (EW)	2	W _k	[a]	[b]
Weight-sensitive Exp.-weighted Manhattan (EIX)	1	e ^{w_k}	[a]	[b]

Proves experimentals (2)


- **EDAR de Girona**
 - 45.000 m3/dia - 70.000 hab.
 - 396 casos reals del període 1995/1996
- **EDAR de Lloret**
 - 13.000 m3/dia - 20.000 hab. (winter)
 - 45.000 m3/dia - 150.000 hab. (summer)
 - 234 casos reals del període 1996/1997
- **Conjunt d'entrenament de 10 estoigs**
- **10 mesures de semblança provades** (100 taules de recuperació)
- **Biblioteques de casos inicialitzades amb casos representatius**

Recuperació òptima

Similarity Measure	% Optimal retrieval Lloret's WWTP	% Optimal retrieval Girona's WWTP
Discrete Manhattan (MD)	60	60
Discrete Euclidean (ED)	80	60
Discrete Exponential-weighted Manhattan (EMD)	80	70
Continuous Manhattan (MC)	50	90
Continuous Euclidean (EC)	60	80
Continuous Exponential-weighted Manhattan (EMC)	60	70
Weight-sensitive Manhattan (MW)	60	90
Weight-sensitive Euclidean (EW)	80	90
Weight-sensitive Exponential-weighted Manhattan (EIX)	80	90


Rànquing de recuperació òptima (1)

• EDAR de Girona



Rànquing de recuperació òptima (2)

• EDAR de Lloret




Conclusions de l'avaluació de la similitud

- **Les distàncies contínues i euclidianes** resulten més adequades per a dominis amb **molts valors quantitius ordenats** i pocs valors categòrics no ordenats
- **Les distàncies Manhattan** resulten més adequades per a dominis amb **categòrics ordenats**
- La distància l'**Eixample** es deriva de la Manhattan i **combina atributs continus i discrets**. Sembla millor, però és molt **sensible** als **pesos** i al procés de **discretització**
- La selecció de funcions i la ponderació de les funcions són reptes importants

Competència

Informació que falta



Competència - Informació que falta

Informació que falta (2)


- **Possibles solucions:**
 - Aturar la recerca
 - Cercar a totes les branques de la jerarquia
 - Cercar en altres jerarquies amb diferents ordres de característiques (arbres de discriminació redundants)
 - Cercar a la branca més prometedora
- **Aproximació escollida:**
 - Associar valors de freqüència a cada branca
 - Cercar a la branca amb la freqüència més alta

© Miquel Sánchez i Marrè, KEMLG, IDEAI-UPC, 2023

14

Competència

Problemes amb la discretització




Competència

Cerca infructuosa / pèrdua de casos òptims

Competència - Cerca infructuosa / perdua de casos òptims

Cerca infructuosa a la Biblioteca de Casos

- **Re-exploració** [Sánchez-Marrè et al., 1997]
- **Meta-casos** [Sánchez-Marrè et al., 2000]



Competència - Cerca infructuosa / perdua de casos òptims


Meta-casos (1)

[Sánchez-Marrè et al., 2000]

- **Definició d'un conjunt de casos prototípics**
els *meta-casos*
- **Induir el conjunt relacionat de biblioteques de casos**
 - Diferents característiques rellevants
 - Ordenació discriminant diferent
 - Ponderació diferent
- **Recuperar de la/les biblioteca/biblioteques de casos més rellevants**

© Miquel Sánchez i Marrè, KEMLG, IDEAI-UPC, 2023

20



Competència - Cerca infructuosa / perdua de casos òptims

Comprovació Experimental (1)

- **Biblioteca de casos inicial:** 15 casos representatius del conjunt de dades 96/97 de l'EDAR de Girona
- **Experiment 1**
 - Utilitzant la biblioteca de casos estàndard
- **Experiment 2**
 - Utilitzant els metacasos i el conjunt de 5 biblioteques de casos definides

© Miquel Sánchez i Marrè, KEMLG, IDEAI-UPC, 2023

22


Comprovació Experimental (2)

			Modalities		
Feature	Interpretation (units)	Weight	Low	Normal	High
SS-S	Suspended solids at the output of the plant (mg/l)	9	(0 – 10)	(10 – 20)	(20 – 100)
DQO-S	Chemical oxidizable organic matter at the output (mg/l)	9	(0 – 30)	(30 – 70)	(70 – 200)
DQO-E	Chemical oxidizable organic matter at the input (mg/l)	7	(0 – 300)	(300 – 500)	(500 – 1000)
SS-E	Suspended solids at the input of the plant (mg/l)	6	(0 – 150)	(150 – 300)	(300 – 750)
Q-E	Inflow wastewater (m ³ /d)	5	(0 – 30000)	(30000 – 40000)	(40000 – 60000)
DBO-E	Biodegradable organic matter at the input (mg/l)	8	(0 – 100)	(100 – 250)	(250 – 600)
DQO-D	Chemical oxidizable organic matter at the output of the primary settler (mg/l)	6	(0 – 150)	(150 – 300)	(300 – 600)
SS-D	Suspended solids at the output of the primary settler (mg/l)	6	(0 – 80)	(80 – 200)	(200 – 450)
IVF	Sludge volume index (ml)	8	(0 – 125)	(125 – 220)	(220 – 400)
V30	Measure of the sedimentability of the activated sludge (ml/g)	5	(0 – 150)	(150 – 250)	(250 – 450)


Comprovació Experimental (3)

Discriminant order	Libraries set				
	Standard Library	Underloading	Overloading	Poor sludge settleability	Turbidity
1	SS-S	DQO-E	DQO-E	IVF	IVF
2	DQO-S	SS-E	SS-E	V30	SS-S
3	DQO-E	Q-E	Q-E	SS-S	DBO-E
4	SS-E		DQO-D	DBO-E	
5	Q-E		DBO-E		
6	DBO-E				
7	DQO-D				
8	SS-D				
9	IVF				
10	V30				

Aproximació estàndard





Aproximació amb Meta-Casos



Resultats de la recuperació de casos

Optimal case retrieval	Standard Retrieval (1 library)	Meta-cases retrieval (Libraries set)					
		Standard	Underloading	Overloading	Poor sludge settleability	Turbidity	Total
First (%)	21	75	71	100	29	75	68
Other (%)	54	100	86	100	100	100	93

Eficiència en Temps



Eficiència en Espai

Quan aprendre?

Eficiència en Espai

Espai: Quan aprendre/Oblidar casos?

[Sánchez-Marrè et al., 1997]


- **Categorització de casos**
- **Aprendre només casos rellevants**
 - **Mesura de rellevància**
- **Oblidar casos inútils** i casos **no excepcionals**
 - **Mesura d'utilitat**

Ontologia de casos (1)

- **Useful case** (C_i) $\Leftrightarrow UM(C_i) \geq \delta$
- **Useless case** (C_i) $\Leftrightarrow UM(C_i) < \delta$
- **Relevant case** (C_i) $\Leftrightarrow \text{Minimum } \{d(C_i, C_k)\} \geq \gamma$, where C_k are the cases in the same leaf of the case library tree than C_i , $k \neq i$
- **Redundant case** (C_i) $\Leftrightarrow \text{Minimum } \{d(C_i, C_k)\} < \gamma$, where C_k are the cases in the same leaf of the case library tree than C_i , $k \neq i$
- **Exceptional case** (C_i) $\Leftrightarrow \#(C_k) = 0$, where $\#(C_k)$ is the number of cases in the same leaf of the case library tree than C_i , $k \neq i$
- **Normal case** (C_i) $\Leftrightarrow \#(C_k) > 0$, where $\#(C_k)$ is the number of cases in the same leaf of the case library tree than C_i , $k \neq i$

Ontologia de casos (2)

ATRIBUT 1




Aprentatge: mesura de la rellevància

Quan **aprendre un cas nou** ?

Mesura de rellevància basada en mesura de similitud:


Aprendre un nou cas (C_i) $\Leftrightarrow \text{Minimum } \{d(C_i, C_j)\} \geq \gamma$



Comprovació experimental 1 (1)


- **Llibreria de casos inicial:** 15 casos representatius del conjunt de dades del 96/97 de l'EDAR de Girona
- **Experiment 1**
 - Aprendre el cas $\Leftrightarrow \#casos-mateixa-fula \leq 3$
 - 396 casos processats, 87.3% apresos
- **Experiment 2**
 - Aprendre només els casos **rellevants cases**
 - 396 casos processats, 61% apresos

Comprovació experimental 1 (2)




37

Comprovació experimental 1 (3)



38

Comprovació experimental 1 (4)



© Miquel Sánchez i Marrè, KEMLG, IDEAI-UPC, 2023

39

Comprovació experimental 2 (1)

[Comas et al., 2001]

- 243 **objectes** (dia de funcionament de l'EDAR de Lloret)
- 63 **atributs** (quantitatius i qualitatis)
- **Atribut de classe**: l'estat de funcionament de la planta
- **Valors que falten ("missing")**
- 20 **classes** obtingudes d'un **procés de clustering**

© Miquel Sánchez i Marrè, KEMLG, IDEAI-UPC, 2023

40

Comprovació experimental 2 (2)

Situation	Class #	Nº of days
Normal WWTP-operation in winter days	1	81
Normal WWTP-operation in summer days	2	55
Rainy days	3	3
Storm days	4	3
Underloading	5	12
Overloading	6	1
Nitrification	7	2
Deflocculation	8	5
Bulking sludge due to Thiotrix (affecting the effluent)	9	3
Foaming sludge due to <i>Microthrix</i> with <i>normal</i> microfauna biodiversity	10	17
Summer days with optimal WWTP-operation	11	24
Chlorine shock	12	1
Denitrification in the secondary settler (<i>rising</i>)	13	7
Transition to a bulking-sludge episode due to Thiotrix	14	2
<i>Weak</i> episode of Foaming sludge due to <i>Nocardia</i>	15	4
<i>Severe</i> episode of foaming sludge due to <i>Nocardia</i>	16	5
Foaming sludge due to <i>Nocardia</i> and deflocculation	17	8
Foaming sludge due to <i>Microthrix</i> with <i>very low</i> microfauna biodiversity	18	1
Foaming sludge due to <i>Microthrix</i> and viscous bulking due to <i>Zooglea</i>	19	6
Winter-summer Plant configuration change	20	3

Comprovació experimental 2 (3)

- **10-fold stratified cross validation**
 - Conjunt sencer de 243 exemples
 - 10 conjunts de proves de 24/25 exemples
 - 10 conjunts d'entrenament de 219/218 exemples
- **Característiques observades**
 - Precisió predictiva al conjunt de proves
 - Precisió predictiva en tot el conjunt
 - Nombre d'exemples utilitzats
 - Nombre de funcions utilitzades
 - Interpretació significativa

Comprovació experimental 2 (4)

Nº Attrib.	Type of library	Case Retrieval Accuracy (%)		
		First	Second	Predominant
19	Plain memory	65.8	59.7	68.7
	Hierarchical (relevant cases)	62.5	44.9	52.3
	Hierarchical (all cases)	64.2	44.4	51.1
63	Plain memory	68.7	60.5	70.4

Method	Number of Attributes	Number of Examples	Prediction accuracy on test set (%)	Meaningful Interpretation	Prediction accuracy on whole data set (%)
C4.5 (63 atts)	24	243	63.51	Partially	89.7
CN2 (63 atts)	44	243	63.98	Partially	98.8
BPRI (63 atts)	63	243	58.9	Partially	-
k-NN (63 atts)	63	243	76.38	No	100
J48 (63 atts)	-	243	64.4	Partially	-
J48, bagging with 10 iterations	-	243	70.7	No	-
J48, AdaBoostM1 with 10 iterations	-	243	73.6	No	-
C4.5 (19 atts)	11	243	65.11	Mostly	87.2
CN2 (19 atts)	19	243	65.45	Mostly	95.9
k-NN (19 atts)	19	243	71.22	No	100
Opencase (plain memory)	19	243	68.73	No	100
Opencase (hierarchical, relevant cases)	19	220	62.50	Yes	97.1
Opencase (hierarchical, all cases)	19	243	64.20	Yes	98.8
Opencase (plain memory)	63	243	70.40	No	100

Eficiència en Espai


Quan oblidar?

Oblit

Quan cal **oblidar un cas** ?

El criteri d'oblit està basat en una **mesura d'utilitat** i en la **categorització dels casos**:

Oblidar el cas (C_i) $\Leftrightarrow$ Unuseful(C_i) i Normal(C_i)



Referències

- [Comas et al., 2001] J. Comas, S. Dzeroski, K. Gibert, I. R.-Roda and M. Sánchez-Marrè (2001). Knowledge discovery by means of inductive methods in wastewater treatment plant data. AI Communications 14(1):45-62. January 2001. ISSN 0921-7126.
- [Sánchez-Marrè, 1996] M. Sánchez-Marrè. DAI-DEPUR: an integrated supervisory multi-level architecture for wastewater treatment plants. Ph. D. Thesis. Dept. de Llenguatges i Sistemes Informàtics. Universitat Politècnica de Catalunya. 1996.
- [Sánchez-Marrè et al., 2000] M. Sánchez-Marrè, U. Cortés, I. R.-Roda & M. Poch (2000). Using Meta-cases to Improve Accuracy in Hierarchical Case Retrieval. Computación y Sistemas 4(1):53-63, July 2000.
- [Sánchez-Marrè et al., 1997] Sánchez-Marrè, M., Cortés, U., R.-Roda, I., Poch, M. & Lafuente, J. (1997). Learning and Adaptation in Wastewater Treatment Plants through Case-Based Reasoning. Computer-Aided Civil and Infrastructure Engineering 12(4):251-266.